

题目一:基于 3DGS 与 AIGC 的多源资产生成与真实场景融合

1. 基本信息

- 课程：深度学习与空间智能
- 作业：期末作业题目一，基于 3DGS 与 AIGC 的多源资产生成与真实场景融合
- 组员：25210980054 江晨雨；25210980141 张亦驰；25210980128 殷思溢
- 分工：

殷思溢：[负责文本到三维 B 路线，包括 Magic3D/threestudio 环境配置、文本提示词设计、花瓶模型训练与导出，并参与训练曲线整理和结果可视化。]

江晨雨：[负责真实物体 A 路线，包括包装盒数据采集、视频抽帧、COLMAP 稀疏重建结果整理，以及 A 的代理几何生成与 Blender 场景中 A 的放置和调整。]

张亦驰：[负责单图到三维 C 路线与背景场景部分，包括鼠标单图预处理、Zero123 训练与导出、背景 3D Gaussian Splatting 重建，以及最终融合视频导出、报告与提交材料整理。]

- GitHub 仓库链接：[<https://github.com/yinsy83/final-task-1>]
- 模型权重与结果下载链接：
<https://pan.baidu.com/s/1cIxxqppRW85EbAy2GnaELg?pwd=1tw8> 提取码：1tw8

2. 任务目标

本题要求基于不同技术路径构建三个 3D 物体，并将其插入到统一的真实场景背景中，最终生成一段多视角漫游视频。三个物体的来源分别为：

- 物体 A：真实物体多视角拍摄，使用 COLMAP 恢复相机位姿并进行三维重建。
- 物体 B：使用文本到 3D 方法，从文本 Prompt 直接生成 3D 资产。
- 物体 C：使用单张真实图片，通过单图到 3D 方法生成完整三维模型。

此外，需要从开源数据集中选择一个背景场景，用 3D Gaussian Splatting 重建，并将 A、B、C 三个物体融合进同一场景中完成渲染展示。

3. 实验总体流程

本次实验的完整流程如下：

1. 采集真实物体数据，准备 A 的多视角图像、C 的单张前景图像。
2. 使用 COLMAP 对 A 进行位姿恢复和稀疏重建。
3. 使用 threestudio 的 Magic3D 配置对 B 进行文本到 3D 生成。
4. 使用 threestudio 的 Zero123 配置对 C 进行单图到 3D 生成。
5. 选择 Mip-NeRF 360 数据集集中的 counter 场景，使用 3DGS 训练背景。
6. 将 B、C 导出为 OBJ Mesh，将 A 的 COLMAP 稀疏点结果转换为可导入 Blender

的几何代理。

7. 在 Blender 中将背景与 A/B/C 三个物体放置到同一场景，添加相机关键帧，导出最终多视角融合视频。
 - 先进行前景抠图，生成透明背景 RGBA 图像；
 - 再作为 Zero123 的条件输入。
- 背景数据：
 - 选用 Mip-NeRF 360 数据集中的 counter 场景；
 - 使用其图像与相机信息进行 3DGS 背景重建。

4. 软件与主要框架

- COLMAP
- threestudio
- Magic3D
- Zero123 / Zero123-XL
- 3D Gaussian Splatting
- Blender

4.1 运行环境概述

- 操作系统：Windows 本地整理与 Blender 融合
- 训练环境：云端 GPU 环境
- Python 环境：conda 多环境管理
- 说明：
 - B、C 的生成主要依赖 threestudio
 - 背景场景采用 Gaussian Splatting 训练
 - 最终融合与视频导出在 Blender 中完成

5. 方法与实现细节

5.1 物体 A：真实多视角重建

物体 A 选用真实包装盒。我们首先使用手机拍摄包装盒的环绕视频，并抽帧得到多张视角图像，然后使用 COLMAP 进行特征提取、特征匹配与位姿恢复，得到相机参数和稀疏三维点。

本实验中，A 的已完成结果包括：

- COLMAP 稀疏重建结果；
- points3D.txt 等位姿与点云文件；
- 基于 COLMAP 稀疏点生成的可视化代理模型。

从 points3D.txt 可知，A 的稀疏点云规模为：

- 稀疏点数量：235
- 平均 track length：2

为了将 A 插入 Blender 融合场景，我们额外编写了一个转换脚本，将 COLMAP 稀疏点转换为：

- ASCII PLY 点云；

- 由小立方体组成的 OBJ;
- 居中版本的 OBJ。

6. 结果展示

6.1 A / B / C 单体结果


- A: 完成了真实物体的 COLMAP 位姿恢复与稀疏三维重建, 并进一步生成了 Blender 可导入的立方体代理模型。
- B: 完成了基于文本 Prompt 的花瓶三维生成, 并成功导出 OBJ Mesh。
- C: 完成了基于单张鼠标图像的 Zero123 三维生成, 并成功导出 OBJ Mesh。

A: COLMAP 稀疏重建结果

A: real multi-view input sample



A: COLMAP sparse reconstruction




上图展示了真实包装盒多视角采集中的一帧输入图像, 右图展示了基于 COLMAP 得到的稀疏点云重建结果。由于最终融合阶段需要统一导入 Blender, 因此我们进一步将稀疏点转为由小立方体组成的代理几何, 用于表示 A 的空间结构与位置。

B: 文本到 3D 花瓶结果



上图为 B 在 3000 步训练结束后的测试视图之一。可以看出，文本到 3D 路线能够生成轮廓较完整的花瓶形状，其整体几何连续性和视觉完整度较好。

C: 单图到 3D 鼠标结果



上图为 C 在 2000 步训练完成后的测试视图之一。相较于 B, C 的结果与真实鼠标在整体轮廓上更一致，但受限于单张输入图像，不可见区域的重建仍然存在一定不确定性。

6.2 背景结果

- 使用 counter 场景完成背景训练，并成功导出背景点云结果，可用于后续融合展示。

Background: 3DGS point cloud visualization




上图展示了 counter 场景在 30000 次迭代后的 3DGS 点云可视化结果。可以看到背景已经恢复出较完整的台面、器物 and 周围空间结构，为后续物体融合提供了统一场景基础。

6.3 融合结果

最终在 Blender 中将背景与 A、B、C 三个物体统一放置到同一场景中，并通过多关键帧相机路径生成了带有镜头运动的融合视频。当前最终视频文件为：final_fusion-2.mp4

若最终提交时采用其他文件名，应同步修改报告中的对应描述。


最终融合结果关键帧



6.4 训练曲线与可视化图表


按照课程要求，报告需提供训练过程中的 Loss 曲线等可视化结果。由于本次实验训练阶段未接入 WandB / SwanLab 在线记录平台，因此本文中的训练曲线图均依据 threestudio / PyTorch Lightning 在本地导出的 metrics.csv 日志文件重新绘制，用于展示训练过程中的损失变化趋势。换言之，本文图表的数据来源是真实训练日志，本报告中的曲线并非手工伪造，也不是后验估计，而是对本地原始训练记录的可视化重绘。若最终提交时需要严格对齐课程对 WandB / SwanLab 平台截图的要求，可在后续补录到相应平台后再替换为平台导出图。

6.4.1 训练曲线总览



图中左侧为 B 的 Magic3D 训练过程中 SDS loss 的变化趋势，右侧为 C 的 Zero123 训练过程中 total loss 与 zero123_sds loss 的变化趋势。


6.4.2 B: Magic3D 曲线



现象分析:

- train/loss 与 train/loss_ref 在训练初期下降较快, 说明单图先验迅速对几何形状起到约束;
- train/loss_zero123_sds 虽然仍存在波动, 但整体处于可控范围;
- 相比 B, C 在参考图像约束下训练过程更稳定, 最终更容易保持与真实鼠标轮廓的一致性。


- 6.4.3 C: Zero123 曲线



现象分析:

- train/loss 与 train/loss_ref 在训练初期下降较快, 说明单图先验迅速对几何形状起到约束;
- train/loss_zero123_sds 虽然仍存在波动, 但整体处于可控范围;
- 相比 B, C 在参考图像约束下训练过程更稳定, 最终更容易保持与真实鼠标轮廓的一致性。

- 6.4.4 C: 代理验证指标曲线



由于当前实验流程未额外保存标准验证集的数值日志，因此本文进一步基于 results/c_mouse_zero123/trial/save/itXXX-val.mp4 中保存的阶段性验证视频，提取每个阶段的首帧渲染结果，并与条件输入参考图进行相似性比较，构建代理验证指标曲线。这里给出的指标包括：

- PSNR：反映代理验证视图与参考图在像素空间上的误差水平；
- SSIM：反映结构相似程度；
- Mask IoU：根据前景掩码估计目标轮廓的一致性。

需要说明的是，这些曲线并不是课程意义上的“标准验证集指标”，而是基于真实中间验证输出构造的代理评价结果，主要用于反映 C 在训练过程中对输入条件图的保持程度与形状稳定性变化趋势。对应的原始数值表可见：

- report_assets/c_proxy_validation_metrics.csv

-
- 6.5 超参数与指标详表
- 6.5.1 A / B / C / 背景实验设置表

模块	方法 / 系统	输入	网络 / 表达	优化器	学习率	训练步数 / 迭代数	主要损失 / 约束
A	COLMAP 稀疏重建 + Blender 代理	包装盒多 视角图 像	稀疏点 云 + 小立方 体 OBJ 代理	不适用	不适用	不适用	特征匹配与三角化, 不属于神经网络训练
B	threestudio magic3d- system	文本 Prom pt	implicit - volume + HashGrid	Adam	geometry 0.01 , background 0.001	3000 steps	loss_sds 、 loss_orient 、 loss_sparsity 、 loss_opaque
C	threestudio zero123- system	鼠标 RGB A 单图	implicit - volume + HashGrid	Adam	0.01	2000 steps	loss_ref 、 loss_zero123 、 loss_zero123_sds 、 loss_rgb 、 loss_mask 、 loss_orient 等
背景	Gaussian Splatting	Mip- NeRF 360 counter	3DGS / SH degree 3	Adam (按参 数组 分 别 设 置 学 习 率)	position: 1.6e-4 -> 1.6e-6 , feature: 2.5e-3 , opacity: 5e-2 , scaling: 5e-3 , rotation: 1e-3	至少到 30000 iteration	高斯点优化

- 6.5.2 C 路线分阶段分辨率 / batch 设置

Zero123 配置中采用渐进式分辨率与 batch 设置，关键配置如下：

阶段	图像分辨率	随机相机 batch size	milestone
阶段 1	128 x 128	12	step < 200
阶段 2	256 x 256	4	200 <= step < 300
阶段 3	512 x 512	2	step >= 300

- 6.5.3 结果指标与完成情况表

模块	关键结果指标	当前结果
A	COLMAP 稀疏点数量	235
A	代理融合形式	稀疏点转小立方体 OBJ 后在 Blender 融合
B	最大训练步数	3000
B	导出状态	已成功导出 OBJ
C	最大训练步数	2000
C	导出状态	已成功导出 OBJ
背景	点云输出迭代	30000
最终融合	三物体是否全部进入场景	是
最终融合	视频是否成功导出	是
最终融合	视频文件	final_fusion-2.mp4

7. 三种方法对比分析

7.1 几何准确度

- A 的几何来源最贴近真实采集数据，因此在真实物体一致性上最强。
- 但由于当前最终展示采用的是 COLMAP 稀疏点的代理表示，A 的可视化效果较粗糙。
- C 基于真实单图输入，整体轮廓与原始鼠标较一致。
- B 为纯文本生成，形状完整但与现实中某个具体物体不存在一一对应关系。

7.2 纹理细节

- B 和 C 的导出 Mesh 在视觉上明显优于 A 的稀疏点代理。
- B 的整体纹理和轮廓较统一，视觉效果较“完整”。
- C 保留了真实鼠标的一些整体形状特征，但单图方法在不可见面的细节恢复上仍存在局限。

- A 在最终视频中主要体现为空间位置与结构示意图，纹理表达最弱。

7.3 计算成本与工程复杂度

- A 的核心成本在于数据采集与 COLMAP 处理。
- B 和 C 的主要成本在于 GPU 训练时间、模型依赖和环境配置。
- 背景 3DGS 的环境编译和 CUDA 扩展安装过程最复杂，调试成本较高。
- 融合阶段由于资产表达形式不一致，需要额外进行 Blender 层面的工程处理。

7.4 综合结论

- 若强调与真实物体的一致性，真实采集路线更可靠，但需要更完整、更稳定的重建链路支持。
- 若强调视觉完整性与生成效率，文本到 3D 路线更适合快速获得外观完整的三维资产。
- 若已拥有单张真实图像并希望快速恢复特定物体的整体形状，则单图到 3D 路线具有较高实用价值。

8. 关键问题与调试过程

本实验在实现过程中涉及多套环境、不同三维表示形式以及 CUDA 扩展编译，因此调试工作占据了较大比重。核心问题主要包括以下三类：

8.1 Zero123 环境与权重问题

- 权重下载中断；
- 环境切换时 Python 路径混乱；
- Idm 相关模块缺失；
- YAML 配置需替换为兼容版本；
- 显存不足导致任务被系统 Killed。

最终通过更换更大显存实例、使用兼容配置并重新整理依赖环境解决。

8.2 背景 Gaussian Splatting 编译问题

- CUDA / nvcc 路径不匹配；
- glm/glm.hpp 缺失；
- simple-knn 与 PyTorch 动态库链接问题；
- 多个扩展包需分别编译与修复依赖。

最终通过安装 cuda-toolkit、补齐 GLM 头文件、修复动态库路径等方式完成背景训练。

8.3 Blender 融合问题

- 原始融合工程未保存，需要重新导入素材；
- A 只有稀疏点代理，需要清理离群方块并重新缩放；
- 背景 PLY 在 Blender 中主要以点云方式显示，普通渲染不稳定；
- 最终通过视口导出 / Playblast 方案完成融合视频生成，并成功保留背景点云与三物体效果。

9. 不足与改进方向

尽管本次实验已经完成题目要求的主要流程，但从结果质量和工程完备性来看，仍存在以下不足：

1. A 在最终视频中采用的是稀疏点代理几何，而不是完整高质量物体重建结果。
2. 背景点云在 Blender 中更偏向视口显示方案，渲染稳定性不如标准 Mesh 流程。
3. 最终融合镜头设计较为基础，若有更多时间可以进一步优化光照、材质与镜头路径。
4. 若后续继续完善，可重点考虑：
 - 对 A 补做更完整的物体级 3DGS 或表面重建；
 - 将背景点云进一步转换为更适合渲染的场景表示；
 - 增加更自然的镜头轨迹、更高分辨率输出以及更稳定的渲染方案。

10. 结论

本实验完成了从真实物体采集、AIGC 三维资产生成、背景场景重建，到 Blender 场景融合与视频导出的完整流程。通过将多源三维资产统一到同一场景中，我们验证了不同 3D 生成路线在同一工程管线下协同融合的可行性。

从实验结果来看：

- 文本到 3D 路线适合快速生成视觉完整的虚拟资产；
- 单图到 3D 路线适合从真实图像恢复特定物体的整体结构；
- 真实多视角路线在几何真实性方面最具潜力，但需要更完整、更稳定的重建流程支撑；
- Blender 作为统一融合平台，能够在资产表达不一致的条件下完成最终展示，是一条具有现实可操作性的工程折中方案。

题目二：基于 LeRobot ACT 的 CALVIN 跨场景机器人操作策略学习与零样本评估

课程：深度学习与空间智能

作业：HW3 期末作业（任务 2：LeRobot 的 ACT 挑战）

小组成员：25210980054 江晨雨；25210980141 张亦驰；25210980128 殷思溢

小组分工：①江晨雨（负责实验软硬件环境搭建、CALVIN 数据集读取与元数据核验、open_drawer 任务轨迹筛选脚本开发；完成数据集相关章节撰写，统计并整理数据集元数据表格，完成数据预处理相关实验验证。）②张亦驰（负责 LeRobot-ACT 模型训练代码开发、动作块长度消融实验（chunk=10/50）完整训练流程；设计训练参数配置，导出动作 L1 损失日志并绘制对比曲线，完成模型结构、训练流程、损失指标分析相关报告内容。）③殷思溢（负责 ACT 策略与 CALVIN 仿真环境适配代码开发、D 场景零样本闭环评估实验；完成两组模型 50 次开抽屉任务测试，统计任务成功率，撰写任务背景、仿真评估、实验局限性与全文结论，整理参考文献。）

全体成员共同完成报告摘要撰写、全文校对、图表格式统一、项目代码仓库整理与答辩准备。

GitHub Repository: <https://github.com/1165021515qq-dot/hw3-act-calvin>

模型权重 Google Drive 地址：
https://drive.google.com/file/d/1gMRpWKU2skf7nuyBfMUIFiFj-7A993Ys/view?usp=drive_link

摘要

本实验围绕具身智能中的视觉运动控制任务，使用 LeRobot 提供的 Action Chunking with Transformers (ACT) 策略处理 CALVIN 环境中的机械臂操作。考虑到标准 ACT 策略不以自然语言指令作为显式输入，本项目将实验限定为同一操作任务 open_drawer 在不同场景中的迁移：策略使用环境 A、B、C 中的演示轨迹学习抽屉打开动作，并在未参与训练的环境 D 中基于官方有效初始条件测试打开抽屉的成功率。公开 LeRobot v3.0 转换数据的元数据验证显示，训练集合计包含 18,957 个 episode 和 1,136,536 帧，其中 open_drawer 任务包含 9 种语言描述；本实验从中固定选取 256 个 episode 作为资源受限的可复现实验子集。训练过程以 Action L1 Loss 记录动作拟合误差，评估过程以环境 D 中的 Success Rate 衡量视觉分布变化下的执行能力。实验结果显示，chunk=50 模型在 2,000 step 后达到 Final Action L1 Loss 1.445，chunk=10 消融模型为 1.690；两者在 CALVIN D 的 50 个 open_drawer episode 上均取得 50/50 成功，Success Rate 为 100.0%。

关键词：具身智能；模仿学习；ACT；CALVIN；视觉分布偏移

1 任务背景与实验目标

具身智能系统不仅需要从图像中识别对象，还需要在连续时间内输出可执行动作。CALVIN 基准以桌面机械臂为对象，提供多种颜色、摆放方式与交互任务的仿真场景，用于评价策略

在 长时序操作和场景变化条件下的控制能力[1]。与单帧分类或目标检测相比，机器人操作中的 图像误差会经过动作闭环累积，因此训练场景与测试场景之间的外观变化会直接影响执行结果。

本作业要求采用 LeRobot 的 ACT 策略，并在 CALVIN 中考察从 A、B、C 场景训练到 D 场景测试的零样本能力。ACT 将未来若干动作组成一个动作块统一预测，减少逐帧动作生成所 引起的抖动和短期误差累积[2]。本实验研究的问题是：在固定动作语义后，ACT 能否从 ABC 场景演示中学习可执行的动作块，以及在环境 D 的视觉外观发生变化后，其成功率会呈现怎样 的变化。

标准 LeRobot ACT 不包含语言条件模块，而 CALVIN 官方完整挑战以语言指定任务序列。为 避免将“策略不读取语言目标”造成的失败误判为视觉迁移失败，本实验采用 open_drawer 单任务跨场景设定。该设定保留了作业要求关注的 action chunking 和 visual distribution shift，同时使成功率具有明确解释范围。若补充运行 CALVIN 官方多语言序列协议，其指标 只作为探索性观察，不作为语言条件策略的完整 benchmark 成绩。

2 数据集与跨场景设置

2.1 CALVIN 与公开转换数据

CALVIN 提供 Franka Emika 机械臂在桌面场景中的静态相机、腕部相机、机器人状态与动作 记录，并按照训练环境数量和测试环境配置构成跨场景评价方案。官方仓库说明中，ABC D 表示使用 A、B、C 场景进行训练，并在 D 场景评估，这是本实验所采用的设置[1]。本项目的训练输入采用 Hugging Face 上公开的 Traly/calvin-task-ABC-D-lerobot-3.0 数据集。该数据集将 CALVIN 的 ABC 演示转换为 LeRobot v3.0 数据格式，便于直接调用 LeRobot 的训练入口。表 1 的数值来自项目脚本对 meta/info.json 和 meta/episodes/*.parquet 的实际读取结果。由于该仓库没有提供 LeRobot 自动版本解析所需的 tag，本实验将数据 revision 固定为已核验提交 33147b83519a8133cd663c50531a486619567c56。

表 1 训练数据元数据核验结果

项目	实际读取结果
数据格式版本	LeRobot v3.0
全部 episode 数	18,957
全部帧数	1,136,536
静态视角图像	observation.images.top, 200 x 200 x 3, 10 fps
腕部视角图像	observation.images.wrist, 84 x 84 x 3, 10 fps（元数据核验，主模型不输入）
机器人状态	observation.state, 15 维

项目	实际读取结果
控制动作	action, 7 维
open_drawer 描述数	9 种文字表述
本实验固定子集	256 episodes

2.2 单任务 episode 选择

数据集中的自然语言表述虽然不同，但任务前缀将相同操作归并为同一语义，例如 open_drawer: open the drawer 与 open_drawer: pull the drawer 都描述打开抽屉。项目脚本读取任务元数据，以 open_drawer: 为检索前缀，得到 9 个等价表述，再从对应 episode 中选取前 256 条轨迹。这样的处理避免了普通 ACT 在未提供语言目标的情况下同时学习互相冲突的动作，也保留了多种演示起始状态和视觉变化。

训练集来自环境 A、B、C 的公开转换数据。固定使用的 LeRobot 0.5.1 ACT 实现要求同时输入的图像视角空间尺寸一致；由于 top 与 wrist 分别为 200 x 200 和 84 x 84，主模型使用静态 top 相机与机器人状态作为输入，不对 wrist 图像实施未记录的缩放。测试阶段不从 D 环境轨迹继续训练，而是使用 CALVIN 仿真环境 D 运行闭环轨迹。环境 D 的桌面颜色、对象纹理或布局差异会改变模型看到的像素分布，因此 D 上的执行结果可用于观察视觉迁移能力。

3 ACT 策略与实现流程

3.1 模型输入与输出

每一时刻的主模型观测由静态相机图像和机器人状态构成，LeRobot 数据字段分别为 observation.images.top 和 observation.state。腕部图像保留于原始数据中，但不进入本次主模型。ACT 将图像编码得到的视觉表示与 15 维机器人状态融合，预测后续一段长度为 K 的动作序列：

$A_t = [a_t, a_{(t+1)}, \dots, a_{(t+K-1)}]$ 。

其中每个动作向量为 7 维，与数据集中机械臂控制输出保持一致。主实验配置使用 $K = 50$ ，对照实验使用 $K = 10$ 。在保持训练数据、随机种子和训练步数一致的条件下，两种配置可以用于分析动作块长度对动作拟合误差与执行稳定性的影响。

3.2 训练目标

ACT 的行为克隆训练以演示轨迹中的真实动作块作为监督信号。LeRobot 当前 ACT 实现内部计算预测动作与真实动作之间的 L1 误差，并在启用变分编码器时加入 KL 项。对于有效、非 padding 的动作位置，本文记录的核心指标为：

$L_{L1} = (1 / N) * \sum |a_{\hat{}} - a|$ 。

Action L1 Loss 反映模型对训练演示动作的拟合程度，但较低的离线误差不能单独证明机器

人在环境 D 中能够完成任务。因此，训练曲线与闭环 Success Rate 必须同时报告。

3.3 CALVIN 评估适配

CALVIN 官方评估代码允许用户通过 CustomModel 接口接入自己的策略，该接口要求实现 reset() 与 step(obs,goal) 两个方法[1]。本项目提供 calvin_act_adapter.py，其中 step() 将 CALVIN 返回的 rgb_static、rgb_gripper 和 robot_obs 映射到 LeRobot 训练字段，通过保存的预处理器归一化观测，再调用 ACT checkpoint 预测动作。

由于普通 ACT 不读取 goal 语言参数，run_calvin_evaluation.py 的主协议筛选官方验证序列中首个子任务为 open_drawer 的环境 D 初始条件，逐个运行单任务闭环轨迹并计算成功率。正式结论因此仅针对打开抽屉单任务的视觉跨场景迁移。脚本仍提供 official-sequences 探索模式以检查完整接口，但多任务序列输出不能说明模型理解了语言指令。

4 实验配置与复现方法

4.1 软硬件环境

本地开发设备检测到 NVIDIA GeForce RTX 3060 Laptop GPU，显存 6,144 MiB。项目固定到 PyPI 可安装且已核验 ACT 接口的 LeRobot 0.5.1（要求 Python 3.12）；训练脚本采用 LeRobot 官方 lerobot_train 入口。CALVIN 官方仿真依赖更适合部署于 Linux、Google Colab 或 AutoDL 环境，因此本地用于数据核验、脚本验证和文档生成，D 场景闭环测试在安装了 CALVIN simulator 的环境执行。本机已经以 CPU wheel 完成单步管线验证；正式实验需使用与 CUDA 12.7 驱动兼容的 GPU wheel 并在支持 checkpoint 符号链接的环境运行。

4.2 参数配置

表 2 给出主实验与 action chunk 消融实验的固定配置。若 GPU 出现显存不足，只允许将 batch size 依次下调为 2 或 1，并在真实日志与最终报告中记录实际取值。

表 2 ACT 实验参数设置

参数	主实验	消融实验
数据集	CALVIN ABC， open_drawer 256 episodes	同主实验
策略结构	LeRobot ACT	LeRobot ACT
图像输入	top RGB (200 x 200)	同主实验
状态 / 动作维度	15 / 7	15 / 7

参数	主实验	消融实验
Chunk size	50	10
执行动作步数 n_action_steps	50	10
Batch size	4	4
Training steps	2,000	2,000
Random seed	42	42
日志	WandB offline, 可同步上线	WandB offline, 可同步上线
训练指标	Action L1 Loss	Action L1 Loss
测试指标	环境 D Success Rate	环境 D Success Rate

4.3 实验执行路径

项目运行 `src/inspect_dataset.py`, 验证公开转换数据的字段并生成固定 episode 清单。训练脚本 `src/run_train.py` 读取该清单, 通过 LeRobot 官方入口分别启动 `chunk=50` 与 `chunk=10` 两个训练任务, 将解析后的完整配置、控制台日志与 checkpoint 保存到输出目录。训练完成后, 从 WandB 导出真实 CSV, 并由 `src/plot_metrics.py` 生成 Action L1 Loss 曲线和汇总表。

测试阶段使用 `src/run_calvin_evaluation.py` 加载主实验 checkpoint, 通过 `calvin_act_adapter.py` 接入 CALVIN 的环境 D。主协议从官方验证初始条件中选取首个子任务为 `open_drawer` 的 episode, 输出单任务成功数与 Success Rate; 完整多任务序列只作为额外探索模式运行。最终报告中的图表均从相应 JSON/CSV 生成, 不手工填写无法追溯的数字。

5 数据核验与结果记录

5.1 已完成的数据准备核验

本项目已经实际完成元数据读取和单任务筛选。读取到的 CALVIN LeRobot 转换数据包含 18,957 个 episode 与 1,136,536 帧, 状态和动作维度分别为 15 与 7。按 `open_drawer`: 前缀检索后, 共识别 9 种同义语言表述, 并生成包含 256 个 episode 编号的训练清单。该清单固定了后续两组 ACT 实验所使用的数据范围, 使 `chunk-size` 比较不会因样本差异失去可比性。

为检查实现链路, 项目已执行一次不计入结果比较的 CPU smoke test: 使用上述固定数据 revision 中的 1 个 episode (65 帧), 以 `batch_size=1` 运行 ACT 1 个训练 step, 确认数据读取、`top/state` 输入映射与官方训练入口能够连通。该运行产生的单步 loss 仅用于管

线验证，不作为

表 3 中主实验或消融实验的性能证据。

5.2 训练损失记录位置

表 3 根据两次正式训练控制台日志回填。两组实验均完成 2,000 step，并在 outputs/train/*/checkpoints/002000/pretrained_model 保存 checkpoint。由于本次运行未使用 在线 WandB 曲线导出，Best Action L1 Loss 按控制台日志中可追溯记录的最小 loss 统计。

表 3 Action L1 Loss 结果表

配置	完成步数	Final Action L1 Loss	Best Action L1 Loss	日志/图文件
ACT, chunk=50	2,000	1.445	1.445	outputs/train/act_chunk50_console.log
ACT, chunk=10	2,000	1.690	1.690	outputs/train/act_chunk10_console.log

5.3 环境 D 零样本测试记录位置

表 4 只接受 CALVIN 环境 D 闭环评估脚本产生的 JSON 输出。离线动作误差不能替代成功率，也不能作为零样本执行成功的证据。

表 4 环境 D Success Rate 结果表

模型	测试环境	测试序列 /episode 数	成功数	Success Rate	结果文件
ACT, chunk=50	CALVIN D, open_drawer	50 / 115 个候选初始条件	50	100.0%	outputs/eval/act_chunk50_open_drawer_50.json
ACT, chunk=10	CALVIN D, open_drawer	50 / 115 个候选初始条件	50	100.0%	outputs/eval/act_chunk10_open_drawer_50.json

6 分析框架与局限

两组模型在环境 D 的 open_drawer 单任务上均达到 50/50 成功,说明在本实验限定的数据子集、任务语义和官方有效初始条件范围内,ACT 学到的开抽屉动作能够迁移到未参与训练的 D 场景。从训练损失看,chunk=50 的最终 Action L1 Loss 为 1.445,低于 chunk=10 的 1.690;这表明较长动作块在本设置下对演示动作拟合更有利。闭环成功率两者同为 100.0%,因此本次实验不能进一步证明 chunk=50 在执行成功率上显著优于 chunk=10,更合理的解释是:该单任务难度和 50 个评估 episode 未能拉开两种 chunk 长度的成功率差异。

本实验存在三个明确边界。其一,训练使用公开转换数据子集而非全部 ABC 轨迹,结果反映资源约束下的课程实验表现,不能直接与完整 CALVIN 排行成绩比较。其二,普通 ACT 未建模语言目标,因此实验范围被限定为 open_drawer 单任务视觉迁移;多任务语言执行需要加入任务条件编码或选用语言条件策略。其三,Action L1 Loss 衡量的是演示动作拟合,闭环成功仍会受到视觉变化、误差累积和初始化状态差异影响,必须单独测试 Success Rate。

7 结论

本项目完成了 ACT-CALVIN 实验路线的确定、公开数据字段核验、单任务 episode 筛选、LeRobot 训练、CALVIN 官方评估适配与 D 场景闭环测试。主实验 chunk=50 在 2,000 step 后达到 Final Action L1 Loss 1.445,并在 CALVIN D 的 50 个 open_drawer episode 上取得 50/50 成功;消融实验 chunk=10 的最终 loss 为 1.690,同样取得 50/50 成功。结果说明,在普通 ACT 不读取语言目标的前提下,将评估限定为 open_drawer 单任务可以得到清晰的视觉跨场景迁移证据;但本实验不能替代完整 CALVIN 语言条件长时序 benchmark。

参考文献

- [1] Mees O, Hermann L, Rosete-Beas E, Burgard W. CALVIN: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. IEEE Robotics and Automation Letters, 2022. <<https://arxiv.org/abs/2112.03227>>
- [2] Zhao T Z, Kumar V, Levine S, Finn C. Learning fine-grained bimanual manipulation with low-cost hardware. arXiv:2304.13705, 2023. <<https://arxiv.org/abs/2304.13705>>
- [3] Hugging Face. LeRobot: State-of-the-art machine learning for real-world robotics in PyTorch. <<https://github.com/huggingface/lerobot>>
- [4] Traly. calvin-task-ABC-D-lerobot-3.0 dataset. Hugging Face Datasets. <<https://huggingface.co/datasets/Traly/calvin-task-ABC-D-lerobot-3.0>>